
# INSTITUTO INFNET PROJETO FINAL DE MÓDULO – INFRAESTRUTURA HADOOP

ALUNO: FLÁVIO PRADO DE AQUINO PROGESOR: ANDRÉ ORMASTRONI VICTOR

Tema: Análise de desempenho do ENEM do ano de 2022, em contrate com o IDH (Índice de Desenvolvimento Humano) por cidade.

1 – Definição e provisionamento de um Cluster Haddop no ambiente Google CDloud



#### 2 – Subir os arquivos CSV do servidor local para o HDFS

```
hdfs dfs -put enem_2022_tratado.csv /user/flaviopradoaquino hdfs dfs -put idh_2010_tratado.csv /user/flaviopradoaquino
```

#### 3 - Provisionar o Beeline Hive

```
beeline -u jdbc:hive2://localhost:10000/default -n flaviopradoaquino@cluster-3a05-m -d org.apache.hive.jdbc.HiveDriver
```

#### 4 - Criar o banco de dados

```
create database if not exists db_enem
comment "Banco de dados Enem"
location "/user/flaviopradoaquino"
with DBPROPERTIES('Date' = '2023-08-30', 'Country' = 'BR' , 'Creator'
= 'Flavio Aquino');
```

## 5 – Criar as tabelas que receberam os dados dos arquivos CSV

```
CREATE TABLE IF NOT EXISTS enem_2022(
NU_INSCRICAO BIGINT,
TP_SEXO STRING,
TP_COR_RACA INT,
TP_ESCOLA INT,
IN_TREINEIRO INT,
CO_MUNICIPIO_PROVA INT,
NO_MUNICIPIO_PROVA STRING,
SG_UF_PROVA STRING,
NU_NOTA_MT INT,
NU_NOTA_REDACAO INT
)
ROW FORMAT DELIMITED FIELDS TERMINATED BY ';'
LINES TERMINATED BY '\n'
STORED AS TEXTFILE;
```

```
CREATE TABLE IF NOT EXISTS idh_2010(
NM_FEDERACAO STRING,
NM_MUNICIPIO STRING,
IDHM DECIMAL,
IDH INT
)
ROW FORMAT DELIMITED FIELDS TERMINATED BY ';'
LINES TERMINATED BY '\n'
STORED AS TEXTFILE;
```

## 6 - Ler os dados dos HDFS para as tabelas do Hive

LOAD DATA INPATH '/user/flaviopradoaquino/idh\_2010\_tratado.csv' overwrite into table idh 2010;

LOAD DATA INPATH '/user/flaviopradoaquino/enem\_2022\_tratado.csv' overwrite into table enem 2022;

select count(\*) from enem\_2022

#### 7 – Consultas realizadas

### >> Média das notas no Enem por cidade pareada com o IDH limitado a vinte saídas

```
select a.no_municipio_prova, AVG(a.nu_nota_redacao), b.idh
from enem_2022 a
join idh_2010 b on a.no_municipio_prova = b.nm_municipio
where a.nu_nota_redacao is not null
order by b.idh desc
group by a.no_municipio_prova, b.idh
limit 20;
```

```
fap 3 ..... container
    1 ..... container
ucer 2 ..... container
                                                                                                   0
     : Completed executing command(queryId=hive_20230831014836_4de4d2b3-a9f8-4068-8bfb-a3cd4ae232d1); Time taken: 14.4 seconds : OK
INFO : Concurrency mode is disabled, not creating a lock manager
 a.no_municipio_prova |
Alfenas
Alvinфolis
Alфa Paraфa
Andrelфdia
                               | 675.8847736625514 | 761
| 642.22222222222 | 676
                                                           | 726
| 700
| 773
| 772
                               | 691.5189873417721
                               | 652.9347826086956
| 678.6111111111111
 Araguari
                                                           | 727
 Areado
                               | 677.1186440677966
                               | 665.0793650793651
| 607.6439790575917
                                                           | 681
| 642
 Almenara
                                                           | 725
| 734
                               Andradas
                                                           | 698
| 684
| 663
| 749
                               | 661.7647058823529
| 649.8795180722891
                                 645.1957295373666
710.8
                               | 588.0392156862745
| 681.7142857142857
                                                             656
                                 674.5846153846154
664.9411764705883
 Belo Horisonte
                                | 692.0523639510981
                                                           I 810
      ws selected (14.994 se
```

#### >> Top 10 dos melhores índices IDH

select NM\_MUNICIPIO, IDH
from idh\_2010
order by IDH desc
limit 10;

### >> Top 20 das melhores notas de redação por cidade e seu respectivo IDH

```
select a.no_municipio_prova, a.nu_nota_redacao, b.idh
from enem_2022 a
join idh_2010 b on a.no_municipio_prova = b.nm_municipio
where a.nu_nota_redacao is not null
order by a.nu_nota_redacao desc
limit 20;
```

```
STATUS TOTAL COMPLETED RUNNING PENDING FAILED KILLED
               VERTICES
                                                            SUCCEEDED
               ..... container
          : Completed executing command(queryId=hive 20230831013214 ddc0cebb-1351-42c2-9847-85f8938587c2); Time taken: 14.721 seconds
          : OK :
: Concurrency mode is disabled, not creating a lock manager
  Governadox Valadares | 1000
Sim Lourenin | 1000
Montes Claros | 1000
Sim Join del Rei | 980
Guaxupin | 980
Timineo | 980
Campo Belo | 980
Sim Join del Rei | 980
Governadox Valadares | 980
Sim Join del Rei | 980
                                                                                       | 727
| 759
| 770
| 758
| 751
| 770
| 711
| 758
| 711
| 758
                                                 980
980
980
980
980
                                                                                       | 758
| 813
| 686
| 770
| 758
    11maseo
S∰o Jo∯o del Rei
Nova Lima
                                                 980
980
980
                                                                                          813
   Campo Belo
So Joo del Rei
                                                                                          812
20 rows selected (15.179 seconds)
```

#### >> Top 20 das melhores notas de redação por cidade e seu respectivo IDH

```
select a.SG_UF_PROVA, AVG(a.nu_nota_mt), AVG(b.idh)
from enem_2022 a
join idh_2010 b on a.no_municipio_prova = b.nm_municipio
where a.nu_nota_redacao is not null
group by a.SG_UF_PROVA
limit 20;
```

```
STATUS TOTAL COMPLETED RUNNING PENDING FAILED KILLED
          VERTICES
                           MODE
                                                                                             0
Map 3 ..... container
                                      SUCCEEDED
Map 1 ..... container
Reducer 2 ..... container
                                      SUCCEEDED
INFO : Completed executing command(queryId=hive_20230831015256_73d1f622-b68a-4d44-a7b0-8b32e562ded2); Time taken: 14.49 seconds
INFO : OK
INFO : Concurrency mode is disabled, not creating a lock manager
                                _c1
                    | 499.67487684729065 | 678.0
| 503.8965517241379 | 715.0
| 495.63793103448273 | 679.0
| 557.5698924731183 | 664.4203187250996
  SP
AL
                     | 535.2739130434783
                                                | 720.0
                                                | 775.0
| 746.8417207792207
  MG
MT
RJ
                      | 571.0769842704755
                     | 514.1058823529412
| 516.3272727272728
                                                | 576.0
| 656.0
  RO
RR
                      | 506.8369565217391 | 672.0
| 452.2 | 637.0
                      | 452.2 | 637.0
| 506.2666666666665 | 715.0
12 rows selected (14.873 seconds)
```

## >> Número de abstenção na prova de redação por cidade limitado a 20 saídas

```
select no_municipio_prova, count(*)
from enem_2022
where nu_nota_redacao is null
group by no_municipio_prova
limit 20;
```

```
STATUS TOTAL COMPLETED RUNNING PENDING FAILED KILLED
                                                    1
2
 Map 1 ..... container
                                                                  1 2
Reducer 2 ..... container
                                   SUCCEEDED
INFO : Completed executing command(queryId=hive_20230903214329_d7605a25-ec83-47ab-8dd8-60175adc78a0); Time taken: 35.285 seconds
INFO : OK
INFO : Concurrency mode is disabled, not creating a lock manager
    no_municipio_prova | _c1
                             | 70
| 26
| 60
 Acaraô
  Acari
  Acopiara
Adamantina
  Adomantina | 43
Afogados da Ingaseira | 49
Afonso Cleadio | 27
Agrestina | 23
  Alagoa Grande
Alagoinha
                             | 60
| 26
                             | 398
| 31
| 172
  Abaetetuba
  Abreu e Lima
                             | 34
   Acrel dadia
                             | 24
| 81
  Afrênio
  Alagoa Nova
    rows selected (39.855 seconds)
```